

Estudio de datos biométricos sobre el ciervo volante. Inferencia estadística.

Olivia Marcos Diaz de Otazu Irene Canales Giménez
Samuel Melián Benito

2025-12-29

Índice

Objetivo del estudio	3
Metodología	3
Análisis de resultados	4
Pregunta 1. ¿Entre qué valores fluctúa el promedio de la anchura de la cabeza y de la longitud de los élitros del <i>Lucanus Cervus</i> ?	4
Pregunta 2.1 ¿Existe diferencia estadísticamente significativa entre el promedio de la anchura de la cabeza según sexo?	4
Pregunta 2.2 ¿Existe diferencia estadísticamente significativa entre el promedio de la longitud de los élitros según sexo?	6
Pregunta 3.1 ¿Existe diferencia estadísticamente significativa entre el promedio de la anchura de la cabeza según si habitan en Cantabria o en Asturias?	7
Pregunta 3.2 ¿Existe diferencia estadísticamente significativa entre la longitud de los élitros según si habitan en Cantabria o en Asturias?	9
Pregunta 4. Suponiendo que la muestra es representativa de la población, ¿los hábitats son igual de numerosos en Cantabria y Asturias?, ¿y en términos de sexo?	10
Resumen de resultados y conclusiones	12
Anexo: Código R	14

Objetivo del estudio

Continuaremos el estudio de datos biométricos del **ciervo volante** (*Lucanus cervus*) estudiando los valores de anchura de cabeza (KB) y longitud de los élitros (EL), y sus diferencias dependiendo de su sexo y procedencia.

El objetivo del estudio es responder a las siguientes preguntas:

1. ¿Entre qué valores fluctúa el promedio de la anchura de la cabeza y de la longitud de los élitros del Lucanus Cervus?
2. ¿Existe diferencia estadísticamente significativa entre el promedio de la anchura de la cabeza y la longitud de los élitros según sexo?
3. ¿Existe diferencia estadísticamente significativa entre el promedio de la anchura de la cabeza y la longitud de los élitros según si habitan en Cantabria o en Asturias?
4. Suponiendo que la muestra es representativa de la población, ¿los hábitats son igual de numerosos en Cantabria y Asturias?, ¿y en términos de sexo?

Y concluiremos comparando las respuestas obtenidas con las conclusiones de la primera práctica de estadística descriptiva. Comprobaremos, utilizando técnicas de inferencia si dichas conclusiones son estadísticamente significativas o sólo responden al azar.

Metodología

Para esta práctica de inferencia y contrastes de hipótesis, utilizaremos en todo momento el conjunto de datos al completo, es decir, los 250 individuos. Excluiremos aquellos cuyo origen es desconocido. Esto supone un cambio en relación con la práctica anterior, en la que se empleaba una muestra aleatoria.

Para resolver las preguntas 1, 2 y 3 se estimaran los intervalos de confianza. Se empleará la distribución t de Student para ver cuál es la tendencia central, así como la dispersión de las variables de estudio. Emplearemos esta prueba para discernir si las diferencias encontradas, entre machos y hembras y según la procedencia, son aleatorias o si, por el contrario, tienen una relevancia estadística.

Asimismo, el factor geográfico será medido empleando un análisis de la varianza ANOVA para comparar los grupos. Además, la prueba Tukey HSD nos proporcionará una mejor comparación entre los pares.

Finalmente, para resolver la pregunta 4 tomaremos los datos de la población en cuanto a provincia y sexo. Se calculará y representará el porcentaje de individuos en dos gráficos que muestren estas distribuciones, y sus resultados nos ofreceran una mejor percepción de la fiabilidad de aquellos obtenidos en la Práctica 1.

Se incluirán tablas a modo de resumen con los resultados de los análisis ya realizados previamente sobre las variables.

Análisis de resultados

Pregunta 1. ¿Entre qué valores fluctúa el promedio de la anchura de la cabeza y de la longitud de los élitros del *Lucanus Cervus*?

El intervalo de confianza al 95% para la media de la **anchura de la cabeza (KB)** es:

$$[11.56, 12.52] \text{ mm}$$

Este primer cálculo del intervalo de confianza para el promedio de la anchura de la cabeza lo hemos realizado mediante la fórmula de intervalo de confianza para la media, siendo desconocida la desviación estándar poblacional. Recordemos que esta fórmula es

$$IC = \bar{X} \pm t_{\frac{\alpha}{2}, n-1} \cdot \left(\frac{s}{\sqrt{n}} \right)$$

Interpretación: Con un nivel de confianza del 95%, el promedio de la anchura de la cabeza de la **población** se encuentra en este intervalo obtenido.

El intervalo de confianza al 95% para la media de la **longitud de los élitros (EL)** es:

$$[20.60, 21.22] \text{ mm}$$

Interpretación: Con un nivel de confianza del 95%, el promedio de la longitud de los élitros de la **población** se encuentra en este intervalo obtenido. Es decir, si repitiéramos el procedimiento con muchas muestras distintas, en el 95% de las ocasiones aproximadamente la media poblacional estaría en este intervalo de confianza.

Pregunta 2.1 ¿Existe diferencia estadísticamente significativa entre el promedio de la anchura de la cabeza según sexo?

Primero presentamos un resumen estadístico de la anchura de la cabeza para cada grupo (hembras y machos) con los datos de la muestra de 250 individuos.

Table 1: Resumen estadístico de la anchura de la cabeza (KB) según sexo

SEXO	N_valid	Pct_valid	Media	Mediana	SD	Min	Max
hembra	118	100	8.894	8.9	0.882	7.2	11.2
macho	132	100	14.846	14.6	3.293	9.0	24.1

Para poder responder esta pregunta tenemos que realizar un contraste de hipótesis para la igualdad de medias.

Hipótesis nula (H_0): La media de KB es igual en ambos sexos.

Hipótesis alternativa (H_a): La media de KB es diferente entre los dos sexos.

Para ello hacemos un test t de Student sobre la muestra de los machos y la muestra de las hembras. Concretamente haremos una prueba t de Welch, que se usa con dos muestras independientes cuando las varianzas no son iguales. Además, conviene su uso al ser las dos muestras de diferentes tamaños.

Table 2: Test t de medias para KB por sexos (Parte 1)

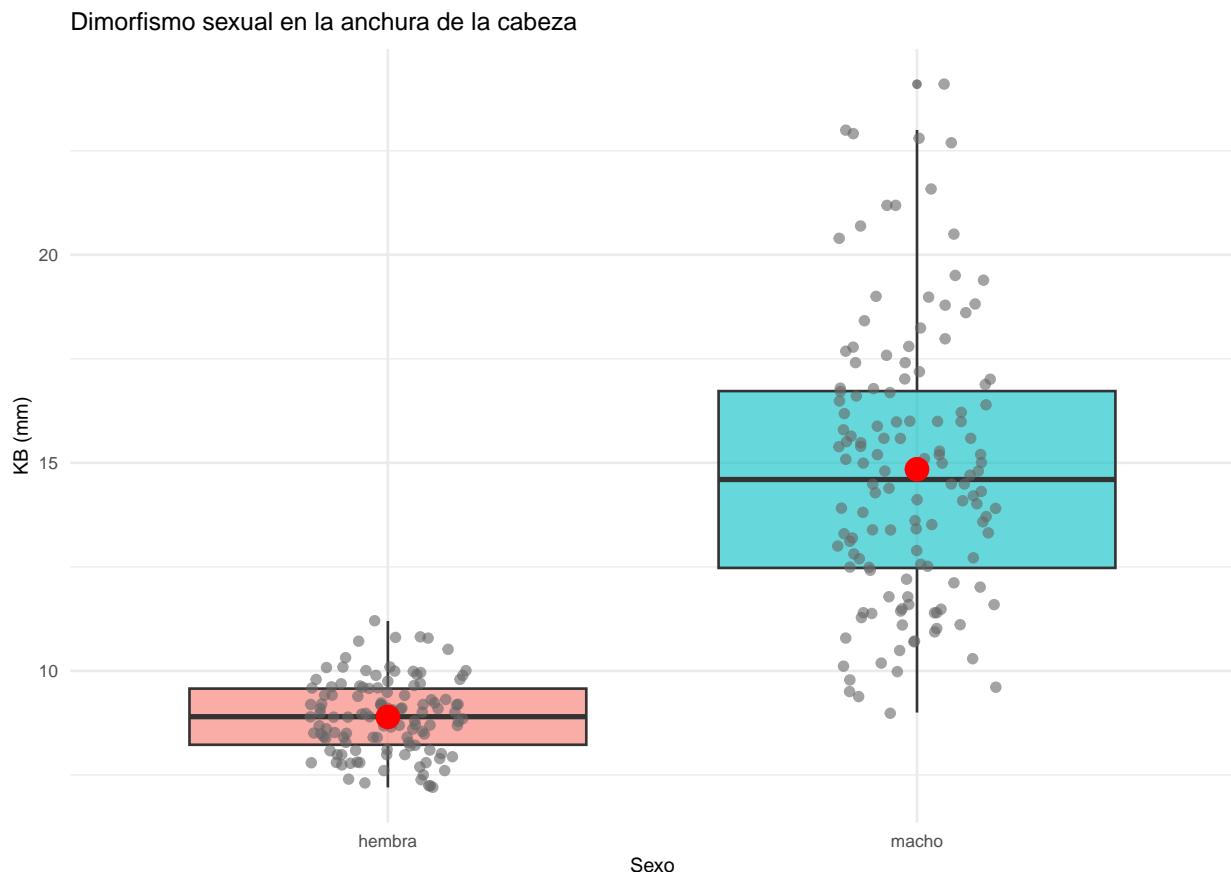
Estadístico t	Grados de libertad	p-Valor
-19.97606	151.7822	0

Table 3: Test t de medias para KB por sexos (Parte 2)

Tamaño del efecto (d de Cohen)	IC 95% (inf)	IC 95% (sup)
2.410409	-6.539955	-5.362729

Interpretación: existe diferencia significativa entre las medias de la anchura de la cabeza entre machos y hembras, el p-Valor es <0.001. El tamaño del efecto es muy grande, lo que indica dimorfismo sexual muy pronunciado. La media para machos es de 14.85mm y la de hembras 8.89mm.

En el siguiente gráfico se puede observar claramente la diferencia entre sexos:



Pregunta 2.2 ¿Existe diferencia estadísticamente significativa entre el promedio de la longitud de los élitros según sexo?

Primero presentamos un resumen estadístico de la longitud de los élitros para cada grupo (hembras y machos) con los datos de la muestra de 250 individuos.

Table 4: Resumen estadístico de la longitud de los élitros (EL) según sexo

SEXO	N_valid	Pct_valid	Media	Mediana	SD	Min	Max
hembra	118	100	19.65	19.7	1.85	15.75	23.5
macho	132	100	22.05	22.2	2.41	15.30	28.3

Para resolver esta pregunta seguimos exactamente el mismo procedimiento, haciendo el t test esta vez para la variable EL.

Table 5: Test t de medias para EL por sexos (Parte 1)

Estadístico t	Grados de libertad	p-Valor
-8.887837	242.6702	0

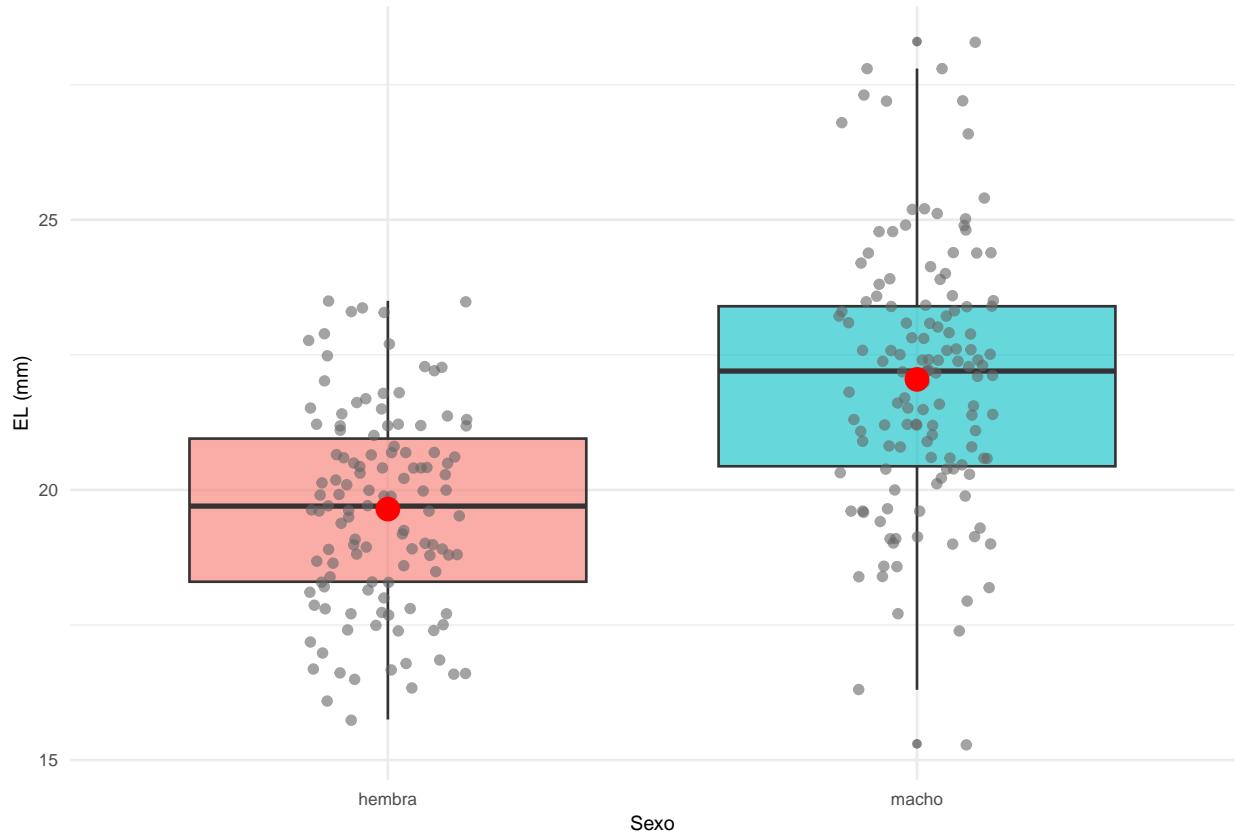
Table 6: Test t de medias para EL por sexos (Parte 2)

Tamaño del efecto (d de Cohen)	IC 95% (inf)	IC 95% (sup)
1.109816	-2.932047	-1.868184

Interpretación: existe diferencia significativa entre las medias de la longitud de los élitros entre machos y hembras, el p-Valor es <0.001. El tamaño del efecto no es tan grande como para la anchura de la cabeza, con lo cual no existe tanta diferencia como en la anterior pero sí que hay diferencia.

En el siguiente gráfico se puede observar la diferencia entre sexos:

Dimorfismo sexual en longitud de los élitros



Pregunta 3.1 ¿Existe diferencia estadísticamente significativa entre el promedio de la anchura de la cabeza según si habitan en Cantabria o en Asturias?

Primero presentamos un resumen estadístico de la anchura de la cabeza para cada procedencia geográfica con los datos de la muestra de 250 individuos.

Table 7: Resumen estadístico de la anchura de la cabeza (KB) según provincia

PROVINCIA	N_valid	Pct_valid	Media	Mediana	SD	Min	Max
Asturias	180	100	11.88	10.80	3.72	7.2	22.7
Cantabria	28	100	13.16	13.35	3.67	8.0	21.2
Otras	42	100	11.94	10.02	4.53	7.4	24.1

Al igual que en el apartado anterior, para responder esta pregunta podríamos realizar un contraste de hipótesis para la igualdad de medias teniendo en cuenta solo el subconjunto de Asturias y de Cantabria.

Hipótesis nula (H_0): La media de KB es igual en ambas provincias.

Hipótesis alternativa (H_a): La media de KB es diferente entre las dos provincias.

Para ello haríamos un test t de Student, concretamente haríamos una prueba t de Welch. No obstante, para ir algo más allá y ofrecer algún resultado adicional, podemos realizar un test ANOVA para entre otras cosas, poder obtener conclusiones sobre la pregunta planteada. Ahora el contraste es:

H_0 : La media de la anchura de la cabeza los 3 grupos es igual.

H_1 : Al menos una media es distinta.

Table 8: ANOVA de un factor para la anchura de la cabeza (KB) según procedencia geográfica

Estadístico F	Grados de libertad entre grupos	Grados de libertad dentro de grupos (residuales)	p-Valor
1.332528	2	247	0.265699

Una vez hecho el test ANOVA, podemos hacer la prueba Tukey HSD (post-hoc) para identificar los pares específicos cuyas medias difieren.

Table 9: Comparaciones múltiples (Tukey HSD) para KB por provincia

Comparación	Diferencia medias	IC 95% (inf)	IC 95% (sup)	p-Valor ajustado
Cantabria-Asturias	1.272698	-0.575950	3.121347	0.237723
Otras-Asturias	0.058413	-1.500973	1.617798	0.995708
Otras-Cantabria	-1.214286	-3.434440	1.005869	0.402350

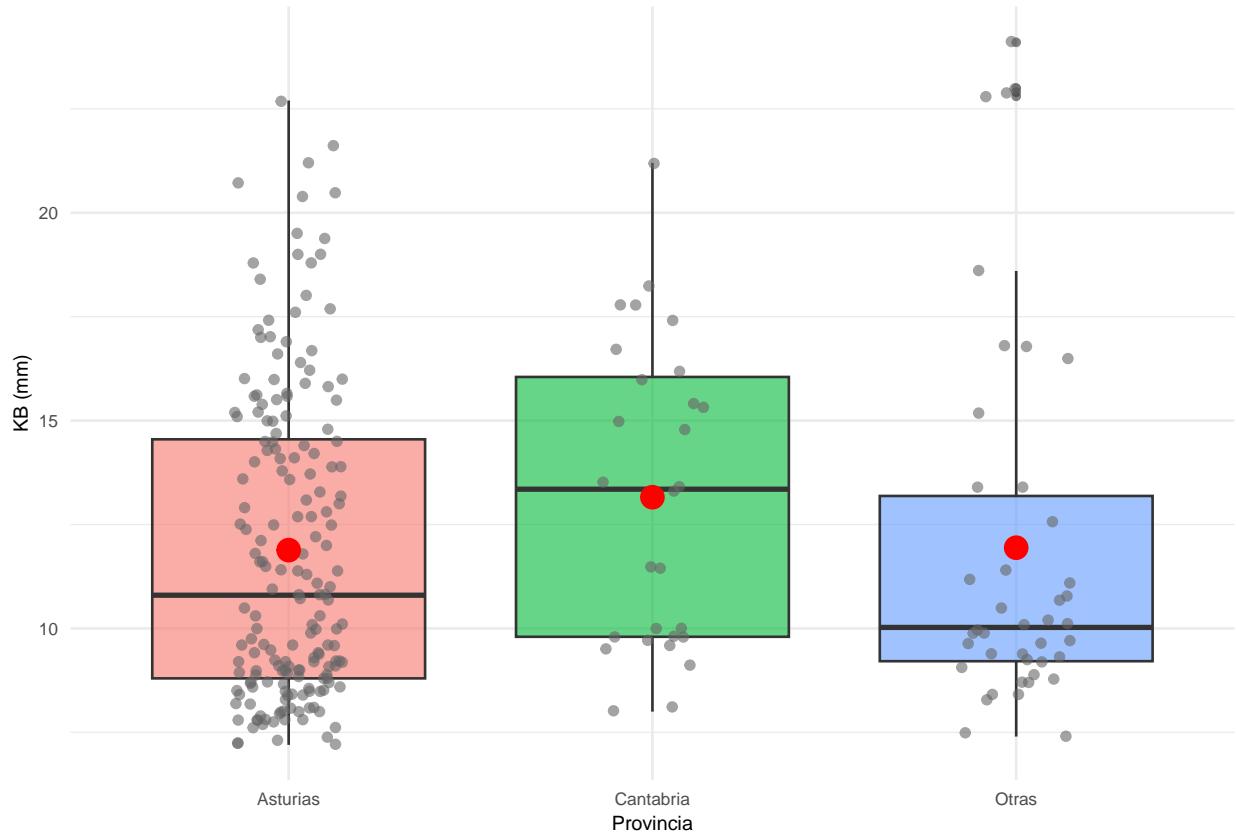
El p-valor que hemos obtenido en el análisis de varianza de un factor (ANOVA) es elevado ($p = 0.265699$), por lo que no se rechaza la hipótesis nula de igualdad de medias.

En consecuencia, no se detectan diferencias estadísticamente significativas en la anchura de la cabeza entre las tres procedencias geográficas (Asturias, Cantabria y Otras).

Además, los resultados del análisis de comparaciones múltiples nos permiten ver que particularmente tampoco hay diferencias de medias estadísticamente significativas entre **Asturias y Cantabria**, lo que refuerza la conclusión anterior.

El siguiente gráfico nos permite ver la variación de la anchura de la cabeza por provincias:

Anchura de la cabeza por procedencia geográfica



Pregunta 3.2 ¿Existe diferencia estadísticamente significativa entre la longitud de los élitros según si habitan en Cantabria o en Asturias?

Primero presentamos un resumen estadístico de la longitud de los élitros para cada procedencia geográfica con los datos de la muestra de 250 individuos.

Table 10: Resumen estadístico de la longitud de los élitros (EL) según provincia

PROVINCIA	N_valid	Pct_valid	Media	Mediana	SD	Min	Max
Asturias	180	100	20.76	20.65	2.46	15.3	27.3
Cantabria	28	100	21.53	21.50	2.11	16.7	27.2
Otras	42	100	21.14	20.55	2.68	16.6	28.3

De nuevo, hacemos un test ANOVA y un análisis post hoc de Tukey para confirmar el resultado, esta vez para la variable EL.

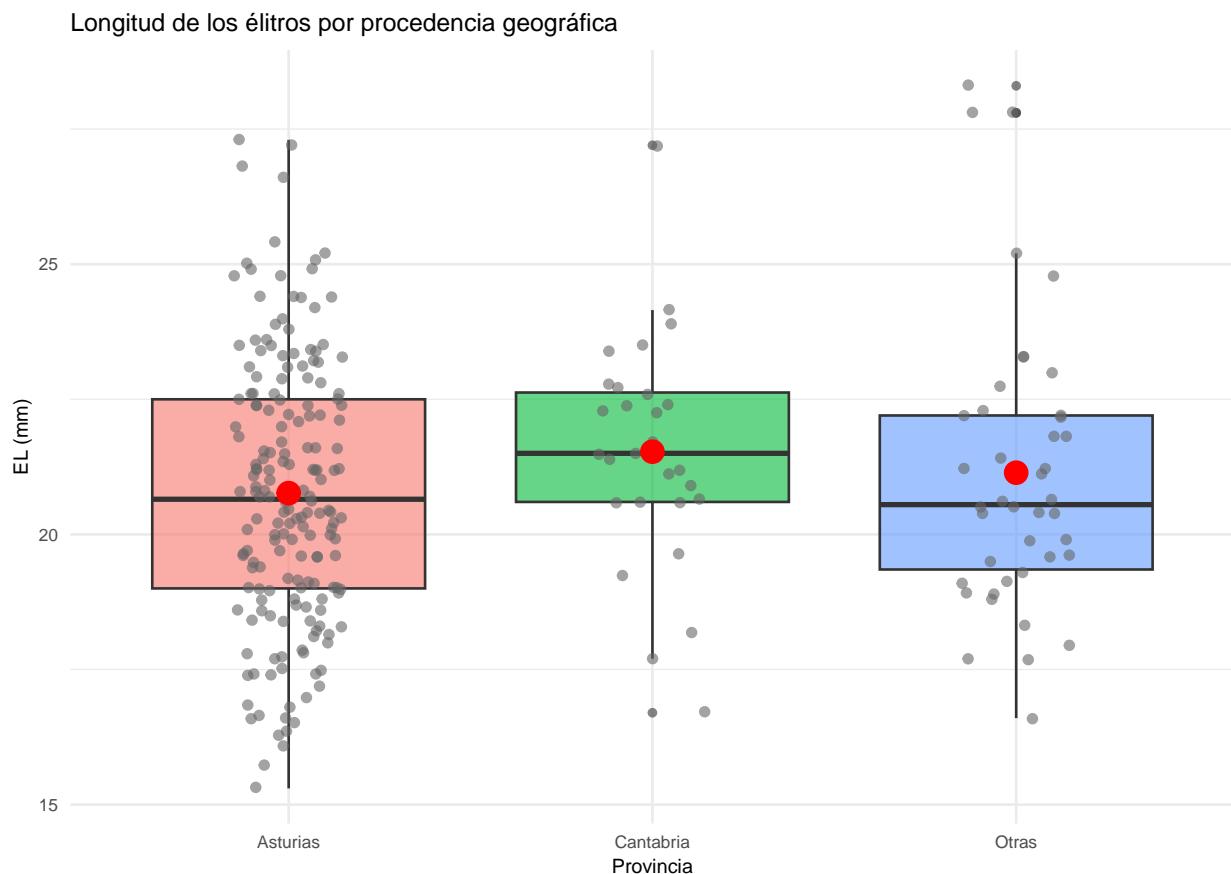
Table 11: ANOVA de un factor para la longitud de los élitros (EL) según procedencia geográfica

Estadístico F	Grados de libertad entre grupos	Grados de libertad dentro de grupos (residuales)	p-Valor
1.390908	2	247	0.250791

Table 12: Comparaciones múltiples (Tukey HSD) para EL por provincia

Comparación	Diferencia medias	IC 95% (inf)	IC 95% (sup)	p-Valor ajustado
Cantabria-Asturias	0.767302	-0.413877	1.948480	0.277856
Otras-Asturias	0.378611	-0.617745	1.374968	0.643339
Otras-Cantabria	-0.388690	-1.807240	1.029859	0.794754

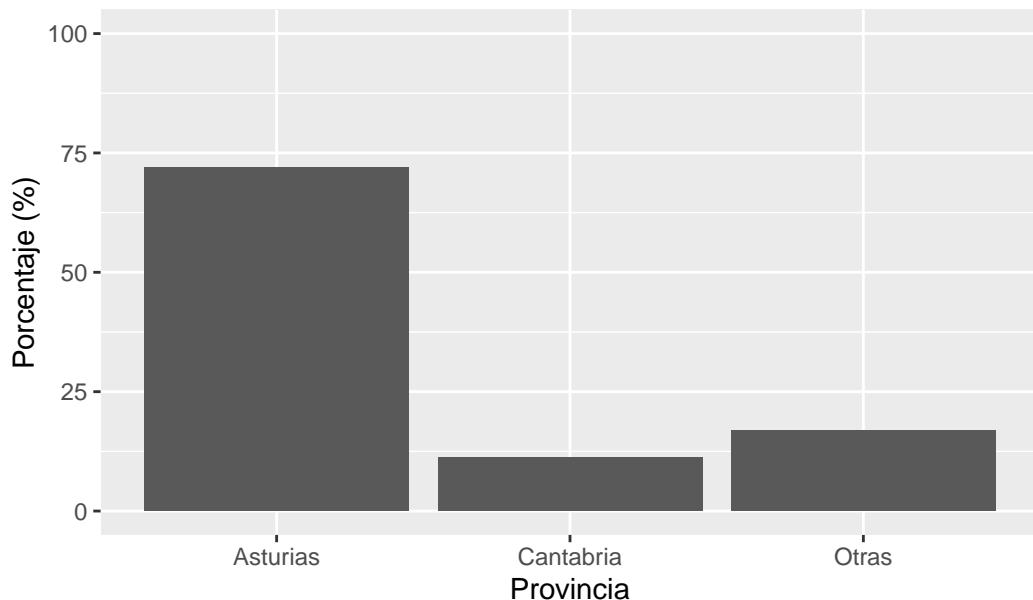
De nuevo, el análisis de varianza de un factor no muestra diferencias estadísticamente significativas en la longitud de los élitros entre las procedencias geográficas ($p = 0.250791$). El análisis post hoc de Tukey confirma el resultado, ya que ninguna de las comparaciones por pares presenta un p-valor ajustado inferior a 0.05, incluyendo la comparación entre **Asturias** y **Cantabria**.



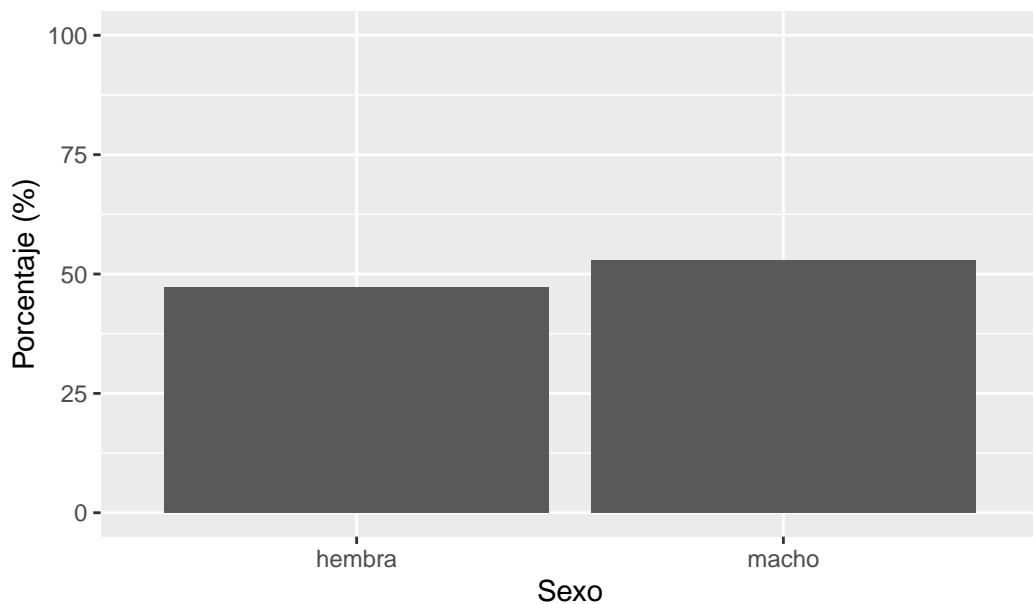
Pregunta 4. Suponiendo que la muestra es representativa de la población, ¿los hábitats son igual de numerosos en Cantabria y Asturias?, ¿y en términos de sexo?

Presentamos a continuación los dos gráficos que representan el porcentaje de individuos de cada provincia y de cada sexo:

Distribución porcentual por provincia



Distribución porcentual por sexo



Interpretación: en cuanto a la distribución geográfica de la **población** podemos observar que la mayoría de registros provienen de Asturias (un 72%), mientras que Cantabria aporta el 11,2% y el 16,8% restante pertenece a otras provincias. Considerando que la muestra es representativa, se observa que Asturias concentra una mayor proporción de registros que Cantabria, luego los hábitats no son igualmente numerosos.

Respecto al sexo de los individuos, se observa una distribución relativamente equilibrada, con ligera predominancia de los machos con un 52,8% frente al 47,2% de las hembras.

Resumen de resultados y conclusiones

Table 13: Resumen de los análisis estadísticos realizados

Analisis	Test	Estadistico	p.valor	Resultado
KB (por sexo)	t de Student	$t = -19.976$	0.000	Concluyente
KB (por provincia)	ANOVA	$F = 1.333$	0.266	Alto, no concluyente
EL (por sexo)	t de Student	$t = -8.888$	0.000	Concluyente
EL (por provincia)	ANOVA	$F = 1.391$	0.251	Alto, no concluyente

En la tabla anterior podemos ver un resumen de los test que hemos llevado a cabo, así como una rápida interpretación de lo que nos indican.

En los análisis por sexo de ambas variables, KB y EL, observamos un resultado con un p valor tal que $p < 0.001$ empleando el análisis de t de Student. Esto indica una fuerte evidencia de la existencia de diferencias reales entre machos y hembras, y se puede concluir que existen dichas diferencias, y que ha sido comprobado estadísticamente.

Por otro lado, para el test ANOVA en ambas variables, se han obtenido unos p valores de entre 0.20 y 0.27. Dada la interpretación de que las diferencias se pueden dar por azar hasta en un 27% de los casos, no podemos obtener una conclusión tan obvia. Se trata de un valor demasiado alto, por lo que no podemos asegurar que estas diferencias se deban al origen de los ejemplares por provincias.

Conclusiones

Tras este análisis empleando inferencia estadística sobre los datos biométricos del ciervo volante, hemos obtenido las siguientes conclusiones. Cabe destacar que gran parte del interés de esta práctica radica en la comparación de este estudio con el realizado previamente a través de la estadística descriptiva, en la práctica 1.

Para comenzar, hemos analizado la variable Anchura de la cabeza (KB) y los resultados confirman lo que ya se veía en la práctica anterior. En ella se tenía que la estimación de la media de la muestra escogida estaba en un 12.14mm. Este valor se encuentra dentro del intervalo de confianza que se ha calculado para la media poblacional en la pregunta 1.

En el caso de la variable Longitud de los élitros (EL), no se realizó en la Práctica 1 un análisis descriptivo tan exhausto como para la variable KB, pero el intervalo de confianza calculado es considerablemente preciso.

A continuación, gracias a los resultados de los análisis de la pregunta 2, podemos confirmar un dimorfismo sexual muy acentuado. Para ambas variables se concluye que los machos poseen valores mayores, de media, en relación con las hembras. Así, se confirma que estos tendrán una mayor anchura de la cabeza y mayor longitud de sus élitros debido a su sexo. Esto también es algo que se había observado en la práctica anterior, y que queda de nuevo confirmado.

Tomando ahora el sesgo geográfico, recordemos que no obtuvimos conclusiones claras en el análisis descriptivo, pues las diferencias no eran significativas. En este nuevo análisis los p valores de la tabla tampoco indican una evidencia clara de la influencia del factor geográfico en las diferencias morfológicas que presentan los ejemplares. El análisis de la varianza y las comparaciones realizadas

indican que las diferencias entre provincias podrían ser debidas al azar hasta en un 27% de los casos, lo cual indica una morfología homogénea de los ejemplares en todas las provincias estudiadas.

En la última parte de esta práctica, la pregunta 4, se buscaba confirmar si existían diferencias en términos de número de ejemplares según el sexo y la provincia. Los resultados confirman que existe una ligera predominancia de ejemplares machos sobre los ejemplares hembras. Además, se tiene un mayor número de ejemplares de Asturias, seguidos de los procedentes de otros lugares, siendo los menos numerosos los venidos de cantabria. Luego la distribución por sexo es suficientemente equitativa, pero la distribución geográfica sí presenta diferencias más relevantes.

En conclusión, los resultados obtenidos empleando inferencia estadística confirman aquellos obtenidos en el análisis descriptivo. Las variaciones morfológicas observadas en la especie de estudio se pueden explicar debido al factor sexual, y sin embargo no podemos dar una conclusión acerca de la influencia del factor geográfico, que no parece tener un efecto significativo. Esto demuestra una validez en el estudio realizado entre ambas prácticas, y confirma que se han obtenido resultados robustos en torno a la población de estudio.

Anexo: Código R

```
knitr::opts_chunk$set(echo = FALSE, warning = FALSE, message = FALSE)
library(tidyverse)
library(summarytools)
library(GGally)
library(gt)
library(flextable)
library(knitr)
library(corrplot)
library(ggplot2)
library(dplyr)
library(kableExtra)
library(effsize)
library(ggstatsplot)
datos <- read.table("./datos/CIERVO.txt", fill=TRUE, dec = ",", header=TRUE );

datos$SEXO <- factor(datos$SEXO, levels = c("hembra", "macho"))
datos$PROVINCIA <- factor(datos$PROVINCIA, levels = c("Asturias", "Cantabria",
  "Otras"))

datos <- datos |> dplyr::filter(!is.na(PROVINCIA))
calcular_ic <- function(datos, alpha) {
  n <- length(datos) #Tamaño del dataset
  media <- mean(datos) #Media de los datos
  s <- sd(datos) #Desviación estándar de los datos
  t_critico <- qt(1 - alpha/2, df = n - 1) #valor crítico de la t-student (alpha
  es el nivel de confianza t n los grados de libertad de la t-student)
  error_estandar <- s / sqrt(n)
  ME <- t_critico * error_estandar
  c(media - ME, media + ME) #Intervalo de confianza
}
IC_KB <- calcular_ic(datos$KB, 0.05)
IC_EL <- calcular_ic(datos$EL, 0.05)
datos %>%
  group_by(SEXO) %>%
  summarise(
    N_valid = sum(!is.na(KB)),
    Pct_valid = N_valid / n() * 100,
    Media = mean(KB, na.rm = TRUE),
    Mediana = median(KB, na.rm = TRUE),
    SD = sd(KB, na.rm = TRUE),
    Min = min(KB, na.rm = TRUE),
    Max = max(KB, na.rm = TRUE)
  ) %>%
  kable(
    caption = "Resumen estadístico de la anchura de la cabeza (KB) según sexo",
```

```

    digits = 3,
    booktabs = TRUE
) %>%
kable_styling(
  latex_options = c("hold_position", "striped")
)
test_KB_sexo = t.test(KB ~ SEXO, data = datos, var.equal = FALSE)

cohen_d <- cohen.d(KB ~ SEXO, data = datos, pooled = TRUE, hedges.correction =
  FALSE)

tabla_kb <- data.frame(
  t = unname(test_KB_sexo$statistic),
  gl = unname(test_KB_sexo$parameter),
  p_valor = test_KB_sexo$p.value,
  d_cohen = abs(cohen_d$estimate),
  IC_inf = test_KB_sexo$conf.int[1],
  IC_sup = test_KB_sexo$conf.int[2]
)
tabla_kb[, 1:3] |>
  kable(
    col.names = c("Estadístico t", "Grados de libertad", "p-Valor"),
    caption = "Test t de medias para KB por sexos (Parte 1)",
    digits = 6,
    booktabs = TRUE,
    align = "c"
  ) |>
  kable_styling(latex_options = c("hold_position","striped"), font_size = 9)

tabla_kb[, 4:6] |>
  kable(
    col.names = c("Tamaño del efecto (d de Cohen)", "IC 95% (inf)", "IC 95%
  (sup)"),
    caption = "Test t de medias para KB por sexos (Parte 2)",
    digits = 6,
    booktabs = TRUE,
    align = "c"
  ) |>
  kable_styling(latex_options = c("hold_position","striped"), font_size = 9)
ggplot(datos, aes(x = SEXO, y = KB, fill = SEXO)) +
  geom_boxplot(
    alpha = 0.6,
    outlier.shape = 16) +
  geom_jitter(
    width = 0.15,
    alpha = 0.6,
    size = 1.5,
    color = "grey40") +

```

```

stat_summary(
  fun = mean,
  geom = "point",
  size = 4,
  color = "red"
) +
labs(
  title = "Dimorfismo sexual en la anchura de la cabeza",
  x = "Sexo",
  y = "KB (mm)"
) +
theme_minimal() +
theme(legend.position = "none") +
theme(
  plot.title = element_text(size = 10),
  axis.title = element_text(size = 8),
  axis.text = element_text(size = 7)
)
datos %>%
  group_by(SEXO) %>%
  summarise(
    N_valid = sum(!is.na(EL)),
    Pct_valid = N_valid / n() * 100,
    Media = mean(EL, na.rm = TRUE),
    Mediana = median(EL, na.rm = TRUE),
    SD = sd(EL, na.rm = TRUE),
    Min = min(EL, na.rm = TRUE),
    Max = max(EL, na.rm = TRUE)
  ) %>%
  kable(
    caption = "Resumen estadístico de la longitud de los élitros (EL) según",
    ` ` ` sexo`,
    digits = 2,
    booktabs = TRUE
  ) %>%
  kable_styling(
    latex_options = c("hold_position", "striped")
  )
test_EL_sexo = t.test(EL ~ SEXO, data = datos, var.equal = FALSE)

cohen_d <- cohen.d(EL ~ SEXO, data = datos, pooled = TRUE, hedges.correction =
` ` ` FALSE)

tabla_el <- data.frame(
  t = unname(test_EL_sexo$statistic),
  gl = unname(test_EL_sexo$parameter),
  p_valor = test_EL_sexo$p.value,
  d_cohen = abs(cohen_d$estimate),

```

```

IC_inf = test_EL_sexo$conf.int[1],
IC_sup = test_EL_sexo$conf.int[2]
)
# Primera mitad
tabla_el[, 1:3] |>
  kable(
    col.names = c("Estadístico t", "Grados de libertad", "p-Valor"),
    caption = "Test t de medias para EL por sexos (Parte 1)",
    digits = 6,
    booktabs = TRUE,
    align = "c"
) |>
  kable_styling(latex_options = c("hold_position","striped")), font_size = 8

# Segunda mitad
tabla_el[, 4:6] |>
  kable(
    col.names = c("Tamaño del efecto (d de Cohen)", "IC 95% (inf)", "IC 95%
      ↵ (sup)"),
    caption = "Test t de medias para EL por sexos (Parte 2)",
    digits = 6,
    booktabs = TRUE,
    align = "c"
) |>
  kable_styling(latex_options = c("hold_position","striped")), font_size = 8
ggplot(datos, aes(x = SEXO, y = EL, fill = SEXO)) +
  geom_boxplot(
    alpha = 0.6,
    outlier.shape = 16) +
  geom_jitter(
    width = 0.15,
    alpha = 0.6,
    size = 1.5,
    color = "grey40") +
  stat_summary(
    fun = mean,
    geom = "point",
    size = 4,
    color = "red"
) +
  labs(
    title = "Dimorfismo sexual en longitud de los élitros",
    x = "Sexo",
    y = "EL (mm)"
) +
  theme_minimal() +
  theme(legend.position = "none") +
  theme(

```

```

    plot.title = element_text(size = 10),
    axis.title = element_text(size = 8),
    axis.text  = element_text(size = 7)
)
datos %>%
  group_by(PROVINCIA) %>%
  summarise(
    N_valid = sum(!is.na(KB)),
    Pct_valid = N_valid / n() * 100,
    Media = mean(KB, na.rm = TRUE),
    Mediana = median(KB, na.rm = TRUE),
    SD = sd(KB, na.rm = TRUE),
    Min = min(KB, na.rm = TRUE),
    Max = max(KB, na.rm = TRUE)
) %>%
  kable(
    caption = "Resumen estadístico de la anchura de la cabeza (KB) según
    ↳ provincia",
    digits = 2,
    booktabs = TRUE
) %>%
  kable_styling(
    latex_options = c("hold_position", "striped")
)
anova_KB <- aov(KB ~ PROVINCIA, data = datos)

res_anova <- summary(anova_KB)[[1]]

tabla_anova_KB <- data.frame(
  est_f = res_anova["PROVINCIA", "F value"],
  gl_1 = res_anova["PROVINCIA", "Df"],
  gl_2 = res_anova["Residuals", "Df"],
  p = res_anova["PROVINCIA", "Pr(>F)"]
)
)

tabla_anova_KB |>
  kable(
    col.names = c(
      "Estadístico F",
      "Grados de libertad entre grupos",
      "Grados de libertad dentro de grupos (residuales)",
      "p-Valor"
    ),
    caption = "ANOVA de un factor para la anchura de la cabeza (KB) según
    ↳ procedencia geográfica",
    digits = 6,
    booktabs = TRUE,
    align = "c"

```

```

) |>
kable_styling(
  latex_options = c("hold_position", "striped"),
  font_size = 10
)

tuk <- TukeyHSD(anova_KB, which = "PROVINCIA")
tuk_tab <- as.data.frame(tuk$PROVINCIA)
tuk_tab$Comparación <- rownames(tuk_tab)
rownames(tuk_tab) <- NULL

tuk_tab <- tuk_tab |>
  dplyr::select(Comparación, diff, lwr, upr, `p adj`)

tuk_tab |>
  knitr::kable(
    col.names = c("Comparación", "Diferencia medias", "IC 95% (inf)", "IC 95%
      ↵ (sup)", "p-Valor ajustado"),
    digits = 6,
    booktabs = TRUE,
    align = "c",
    caption = "Comparaciones múltiples (Tukey HSD) para KB por provincia"
  ) |>
  kableExtra::kable_styling(
    latex_options = c("hold_position", "striped"),
    font_size = 9
  )

ggplot(datos, aes(x = PROVINCIA, y = KB, fill = PROVINCIA)) +
  geom_boxplot(
    alpha = 0.6,
    outlier.shape = 16) +
  geom_jitter(
    width = 0.15,
    alpha = 0.6,
    size = 1.5,
    color = "grey40") +
  stat_summary(
    fun = mean,
    geom = "point",
    size = 4,
    color = "red"
  ) +
  labs(
    title = "Anchura de la cabeza por procedencia geográfica",
    x = "Provincia",
    y = "KB (mm)"
  )

```

```

theme_minimal() +
  theme(legend.position = "none") +
  theme(
    plot.title = element_text(size = 10),
    axis.title = element_text(size = 8),
    axis.text = element_text(size = 7)
  )
datos %>%
  group_by(PROVINCIA) %>%
  summarise(
    N_valid = sum(!is.na(EL)),
    Pct_valid = N_valid / n() * 100,
    Media = mean(EL, na.rm = TRUE),
    Mediana = median(EL, na.rm = TRUE),
    SD = sd(EL, na.rm = TRUE),
    Min = min(EL, na.rm = TRUE),
    Max = max(EL, na.rm = TRUE)
  ) %>%
  kable(
    caption = "Resumen estadístico de la longitud de los élitros (EL) según",
    ↪ provincia",
    digits = 2,
    booktabs = TRUE
  ) %>%
  kable_styling(
    latex_options = c("hold_position", "striped")
  )
anova_EL <- aov(EL ~ PROVINCIA, data = datos)

res_anova <- summary(anova_EL)[[1]]

tabla_anova_EL <- data.frame(
  est_f = res_anova["PROVINCIA", "F value"],
  gl_1 = res_anova["PROVINCIA", "Df"],
  gl_2 = res_anova["Residuals", "Df"],
  p = res_anova["PROVINCIA", "Pr(>F)"]
)
tabla_anova_EL |>
  kable(
    col.names = c(
      "Estadístico F",
      "Grados de libertad entre grupos",
      "Grados de libertad dentro de grupos (residuales)",
      "p-Valor"
    ),
    caption = "ANOVA de un factor para la longitud de los élitros (EL) según",
    ↪ procedencia geográfica",
  )

```

```

    digits = 6,
    booktabs = TRUE,
    align = "c"
) |>
kable_styling(
  latex_options = c("hold_position","striped"),
  font_size = 10
)

tuk <- TukeyHSD(anova_EL, which = "PROVINCIA")
tuk_tab <- as.data.frame(tuk$PROVINCIA)
tuk_tab$Comparación <- rownames(tuk_tab)
rownames(tuk_tab) <- NULL

tuk_tab <- tuk_tab |>
  dplyr::select(Comparación, diff, lwr, upr, `p adj`)

tuk_tab |>
  knitr::kable(
    col.names = c("Comparación", "Diferencia medias", "IC 95% (inf)", "IC 95%
      ↴ (sup)", "p-Valor ajustado"),
    digits = 6,
    booktabs = TRUE,
    align = "c",
    caption = "Comparaciones múltiples (Tukey HSD) para EL por provincia"
) |>
  kableExtra::kable_styling(
    latex_options = c("hold_position", "striped"),
    font_size = 9
  )

ggplot(datos, aes(x = PROVINCIA, y = EL, fill = PROVINCIA)) +
  geom_boxplot(
    alpha = 0.6,
    outlier.shape = 16) +
  geom_jitter(
    width = 0.15,
    alpha = 0.6,
    size = 1.5,
    color = "grey40") +
  stat_summary(
    fun = mean,
    geom = "point",
    size = 4,
    color = "red"
) +
  labs(
    title = "Longitud de los élitros por procedencia geográfica",

```

```

    x = "Provincia",
    y = "EL (mm)"
) +
theme_minimal() +
theme(legend.position = "none") +
theme(
  plot.title = element_text(size = 10),
  axis.title = element_text(size = 8),
  axis.text = element_text(size = 7)
)
datos |>
  count(PROVINCIA) |>
  mutate(porcentaje = n / sum(n) * 100) |>
  ggplot(aes(x = PROVINCIA, y = porcentaje)) +
  geom_col()+
  labs(
    title = "Distribución porcentual por provincia",
    x = "Provincia",
    y = "Porcentaje (%)"
  ) + scale_y_continuous(limits = c(0, 100))

datos |>
  count(SEXO) |>
  mutate(porcentaje = n / sum(n) * 100) |>
  ggplot(aes(x = SEXO, y = porcentaje)) +
  geom_col() +
  labs(
    title = "Distribución porcentual por sexo",
    x = "Sexo",
    y = "Porcentaje (%)"
  )+ scale_y_continuous(limits = c(0, 100))

tabla_resumen <- data.frame(
  Analisis = c(
    "KB (por sexo)",
    "KB (por provincia)",
    "EL (por sexo)",
    "EL (por provincia)"
  ),
  Test = c(
    "t de Student",
    "ANOVA",
    "t de Student",
    "ANOVA"
  ),
  Estadistico = c(

```

```

paste0("t = ", round(unname(test_KB_sexo$statistic), 3)),
paste0("F = ", round(summary(anova_KB)[[1]]$`F value`[1], 3)),
paste0("t = ", round(unname(test_EL_sexo$statistic), 3)),
paste0("F = ", round(summary(anova_EL)[[1]]$`F value`[1], 3))
),

`p-valor` = c(
  signif(test_KB_sexo$p.value, 8),
  signif(summary(anova_KB)[[1]]$`Pr(>F)`[1], 3),
  signif(test_EL_sexo$p.value, 8),
  signif(summary(anova_EL)[[1]]$`Pr(>F)`[1], 3)
),

Resultado = c(
  "Concluyente", "Alto, no concluyente", "Concluyente", "Alto, no concluyente"
)
)

tabla_resumen |>
  kable(
    caption = "Resumen de los análisis estadísticos realizados",
    booktabs = TRUE,
    align = "l"
  ) |>
  kable_styling(
    latex_options = c("hold_position", "striped"),
    font_size = 9
  )

```